DELFOS v2

DDL Schema Analyzer

GUIA COMPLETO

Interpretação do Relatório para Modelagem, BI, Machine Learning e Governança de Dados

Autor: Alessandro Pessoa da Conceição Barreto
alessandro.pessoa@marinha.mil.br · alessandropessoa@gmail.com

Versão 2.1 · 2025

Sobre este Guia

Este documento capacita analistas de negócio, engenheiros de dados, arquitetos de software e cientistas de dados a extrair o máximo de valor da estrutura de um banco de dados, mesmo sem acesso aos dados reais.

O relatório DELFOS transforma scripts SQL (DDL) em um mapa detalhado que revela:

- Quais são as entidades principais e como se relacionam
- Onde estão os gargalos de performance ocultos
- Quais colunas realmente importam para consultas analíticas
- Como priorizar a documentação e a criação de índices
- Onde concentrar esforços em projetos de BI, Data Warehouse e Machine Learning

Seção 0 — Metodologia: A Jornada do DDL pelo Pipeline

Antes de interpretar o relatório, é essencial entender como ele é produzido. O DELFOS v2 opera em um pipeline estruturado de 4 passos. Cada passo produz artefatos numerados que rastreiam a cadeia completa de transformação, do DDL original ao relatório legível com nomes reais.

> PRINCÍPIO CENTRAL: O relatório que você interpreta pode ser gerado sobre um DDL mascarado (seguro para compartilhar) ou sobre o DDL original (para uso interno). A estrutura analítica é idêntica nos dois casos — apenas os identificadores diferem.

Passo 1 — Mascaramento (mask)

01

DDL Original → DDL Mascarado + Mapeamento

Todos os identificadores (tabelas, colunas, índices, constraints) são substituídos por tokens hash determinísticos. O mapeamento JSON gerado é a chave de reversão.

```
delfos mask banco.sql --mode hash --output 01_masked.sql --mapping
02_mapping.json
```

→ **01_masked.sql + 02_mapping.json**

O que acontece internamente:

- O extrator varre o DDL e coleta todos os identificadores por tipo (tabelas, colunas por tabela, índices, constraints).
- O gerador de tokens calcula hashes SHA-256 (8 chars) para cada identificador.
- Regra cross-table (modo hash padrão): colunas com mesmo nome em tabelas diferentes recebem o mesmo token. Ex: ANO em TB_HEADER e em HS_PENSIONISTAS → mesmo C_d207efee. Isso preserva a análise de joins.

- O substituidor realiza duas passagens: primeiro substituições entre aspas duplas ("COL" → "MOCK"), depois word-boundary (COL → MOCK em SELECTs sem aspas).

Passo 2 — Análise do DDL Mascarado (analyze)

02

DDL Mascarado → Relatório Estrutural (sem nomes reais)
O analisador extrai tabelas, colunas, tipos, PKs, FKs, índices e (com sqlglot instalado) JOINs de Views/MVs. O relatório resultante é seguro para compartilhar com LLMs e times externos.

```
delfos analyze 01_masked.sql --style markdown --output 03_report_masked.md
```

→ **03_report_masked.md + 03_structure_masked.json**

Por que analisar o DDL mascarado e não o original?

- O relatório 03_report_masked.md pode ser enviado a um LLM sem risco de exposição de dados sensíveis.
- Times externos (parceiros, auditores, fornecedores de IA) recebem apenas estrutura, não semântica.
- A análise estrutural — tipos, cardinalidade, padrões de join — é idêntica ao original.

Passo 3 — Desmascamento do Relatório (unmask)

03

Relatório Mascarado + Mapeamento → Relatório com Nomes Reais
O desmascador inverte o mapeamento (mock → original) e substitui todos os tokens no relatório. Aplica duas passagens (aspas e word-boundary) para garantir cobertura total.

```
delfos unmask 03_report_masked.md 02_mapping.json --output 04_report_real.md
```

→ **04_report_real.md (uso interno)**

O arquivo 04_report_real.md é o relatório de consumo interno — apresenta os mesmos dados analíticos do arquivo 03, mas com nomes legíveis. Use-o para:

- Reuniões técnicas internas com os nomes reais visíveis.
- Validação do desmascamento (compare com o arquivo 05).
- Documentação interna e governança de dados.

Passo 4 — Análise do DDL Original (validação)

04

DDL Original → Relatório de Referência com Nomes Reais
Análise direta do DDL original, sem nenhuma transformação. Serve como ground truth para validar se o round-trip mask→unmask foi fiel.

```
delfos analyze banco.sql --style markdown --output 05_report_original.md
```

→ **05_report_original.md + 05_structure_original.json**

> VALIDAÇÃO: O arquivo 04_report_real.md (desmascado) deve ter conteúdo estruturalmente idêntico ao 05_report_original.md. A única diferença esperada é a ordenação alfabética das

tabelas, pois os tokens hash têm ordem lexicográfica diferente dos nomes originais. Se houver diferença de conteúdo (colunas ou tabelas faltando), o mapeamento está incompleto.

Visão Consolidada do Pipeline

Artefato	Passo	Contém Nomes Reais?	Compartilhável?	Uso Principal
01_masked.sql	1	❌ Não	✅ Sim	Input para análise segura e LLM
02_mapping.json	1	✅ Sim	🔴 Não	Chave de reversão — guardar em segurança
03_report_masked.md	2	❌ Não	✅ Sim	Análise externa, envio a LLM
03_structure_masked.json	2	❌ Não	✅ Sim	Uso programático, integração
04_report_real.md	3	✅ Sim	🔴 Não	Reuniões internas, documentação
05_report_original.md	4	✅ Sim	🔴 Não	Referência, validação do round-trip
05_structure_original.json	4	✅ Sim	🔴 Não	Integração interna, comparação

Seção 1 — Sumário Geral

O Sumário é o painel executivo do relatório. Ele fornece uma visão de saúde imediata do schema analisado.

Métrica	O que indica	Ação Recomendada
Tabelas físicas	Número de entidades principais do negócio.	Escopo do projeto de modelagem.
Materialized Views	Resultados pré-calculados. Alto valor analítico.	Candidatos a data marts ou tabelas de agregação.
FKs declaradas vs. Tabelas	Relação abaixo de 1:3 indica integridade implícita.	Recorrer à Seção 7 (Joins) para descobrir relacionamentos reais.
Tabelas sem PK	Risco de duplicação e inconsistência.	Alta prioridade: definir chaves lógicas imediatamente.
Arestas de Join	Complexidade analítica das consultas.	Criar índices nas colunas da Seção 7.2 não indexadas.

Seção 2 — Tabelas: Detalhamento de Colunas

Esta seção lista cada tabela com suas colunas, tipos, nulabilidade e indicadores visuais de chave e índice.

Interpretação dos Símbolos

Símbolo	Significado	Implicação
● (PK)	Chave Primária	Identificador único da linha. Garante que não há duplicatas.
◆ (IDX)	Índice Explícito	A coluna participa de um índice, acelerando buscas e joins.
NULL? = NO	Coluna obrigatória	Não aceita valores nulos. Campo essencial para o negócio.
NULL? = YES	Coluna opcional	Pode conter nulos. Em análises, requer tratamento (COALESCE).

Atenção: Ausência de Índice em Colunas Frequentes

Colunas sem o símbolo ◆ mas que aparecem com alta frequência na Seção 7.2 (Joins) indicam gargalo de performance latente. Esta é uma das descobertas mais valiosas do DELFOS.

> Exemplo: ANO, MES, COD_FORCA aparecem em 133 condições de JOIN sem índice declarado → Full Table Scan em cada consulta analítica.

Tipos de Objeto

Tipo	Indicador no Relatório	Uso Analítico
TABLE	Seção 'Tabelas (N)'	Dados transacionais e mestres. Fonte primária de fatos e dimensões.
MATERIALIZED VIEW	Seção 'Materialized Views (N)'	Resultados pré-computados. Excelentes como fonte de dashboards BI.
VIEW	Seção 'Views (N)'	Consultas nomeadas. Revelam os joins mais importantes do sistema.

Seção 3 — Índices Explícitos

Os índices revelam o que já foi otimizado intencionalmente. A ordem das colunas em um índice composto é tão importante quanto quais colunas estão incluídas.

Lendo a Ordem das Colunas

Um índice como (ANO, MES, COD_FORCA, CPF) revela a hierarquia de consulta mais comum do sistema:

- Primeiro filtra-se por ANO
- Depois por MES dentro do ano
- Depois por COD_FORCA dentro do mês
- Finalmente por CPF

Essa hierarquia expõe a estrutura natural de navegação dos dados: Tempo → Força → Indivíduo.

UNIQUE vs. Não-UNIQUE

Tipo	Função	Impacto no Modelo
[UNIQUE]	Garante unicidade + acelera buscas	Funciona como constraint de unicidade. Expõe candidatos a PK alternativa.
Não-UNIQUE	Apenas acelera buscas/filtros	Indica colunas de alta seletividade usadas em WHERE ou JOIN ON.

Seção 4 — Chaves Primárias e Compostas

Tipos de Chaves Compostas e o que Revelam

Padrão de PK Composta	Tipo de Tabela	Significado no Negócio
(ID_UNICA, ID_PESSOAL_MIL, SITUACAO)	Tabela Associativa (N:N)	Um militar pode ter múltiplos benefícios em diferentes situações.
(SITUACAO, ID_PARCELA, COD_ND, NUM, MES_ANO_INI)	Tabela Fato granular	Cada evento atômico é identificado por 5 dimensões.
(NU_ANO_MES_FIM, NU_ANO_MES_INI)	Dimensão com histórico (SCD Tipo 2)	Mantém histórico de mudanças com vigência início-fim.
(ANO, MES, COD_FORCA)	Super-chave dimensional	Dimensão implícita Tempo+Força presente em todo o modelo.

Impacto em Data Warehouse

Chaves compostas no schema OLTP geralmente devem ser substituídas por Surrogate Keys (ex: ID_LANCAMENTO NUMBER gerado por sequence) no modelo dimensional, para simplificar joins e melhorar performance de ETL.

Seção 5 — Relacionamentos: Foreign Keys

Cada FK lida como: TabelaOrigem(Coluna) → TabelaDestino(Coluna) [Nome_Constraint]

Poucas FKs = Alta Dependência da Seção 7

Schemas com baixa razão FK/Tabela (ex: 5 FKs para 74 tabelas) indicam que:

- A integridade referencial é garantida pela aplicação ou pelo ETL, não pelo banco.
- Os relacionamentos reais existem apenas na lógica das consultas SQL (Views, MVs).
- A Seção 7 (Análise de Joins) torna-se a fonte principal do modelo relacional real.

> Regra prática: se FKs / Tabelas < 0,3, trate a Seção 7 como a seção mais importante do relatório.

Seção 6 — Cobertura de Comentários

Matriz de Prioridade de Documentação

Situação	Prioridade	Ação
Tabela com 0 colunas documentadas	🔴 Máxima	Documentar imediatamente. Risco de interpretação incorreta em ML/BI.
Tabela com alta frequência de join sem comentários	🔴 Alta	Priorizar as colunas usadas em join conditions (ver Seção 7.2).
Coluna com nome ambíguo (SITUACAO, COD, TP)	🟡 Média	Esclarecer domínio de valores possíveis no comentário.
Tabela com > 80% das colunas documentadas	🟢 Baixa	Manter e revisar periodicamente.

Seção 7 — Análise de Joins: O Diferencial do DELFOS

Esta é a seção mais valiosa do relatório. Ela extrai padrões de uso real das consultas SQL embutidas em Views e Materialized Views, revelando como as tabelas são efetivamente conectadas na prática — independente do que as FKs declaradas dizem.

7.1 — Tabelas Mais Referenciadas em JOINs

Identifica o 'centro de gravidade' do sistema — a tabela que quase toda análise atravessa.

- A tabela no topo da lista deve ser a Tabela Fato em qualquer modelo dimensional.
- Tabelas com > 50 aparições são candidatas naturais a ter índices em todas as colunas de join.
- Tabelas com poucas aparições (< 5) são provavelmente tabelas de domínio ou auxiliares.

7.2 — Colunas Mais Usadas em Condições de JOIN

Esta é a lista de candidatos a índice B-tree gerada a partir do uso real. Cada coluna aqui representa uma condição ON clause verificada repetidamente.

> AÇÃO DIRETA: Para cada coluna desta lista que NÃO possua ◆ na Seção 2, crie um índice. Isso representa o maior ganho de performance com menor esforço.

SQL template para criação do índice:

```
CREATE INDEX idx_<tabela>_<col1>_<col2>
ON <TABELA> (<COL1>, <COL2>, <COL3>);
```

Ordene as colunas pela frequência decrescente na lista da Seção 7.2 para maximizar o reaproveitamento do índice.

7.3 — Pares de Tabelas Mais Frequentes

Revela os relacionamentos implícitos mais fortes do sistema. Pares com alta frequência (> 50x) representam:

- Relacionamentos que deveriam ter FK explícita declarada.
- Candidatos a dimensões em um modelo Star Schema.
- Linhas com traçado sólido no diagrama Entidade-Relacionamento.

7.4 — Tipos de JOIN

Distribuição	Interpretação	Implicação para o Modelo
> 90% INNER JOIN	Alta integridade referencial na prática.	Dados orfãos são raros. FKs podem ser adicionadas com segurança.
LEFT JOIN frequente (> 20%)	Existem registros sem correspondência.	Colunas do lado direito requerem tratamento NULL em análises.
FULL JOIN presente	Dados parciais em ambos os lados.	Indica lacunas de dados — investigar antes de treinar modelos ML.
CROSS JOIN presente	Produto cartesiano intencional.	Verificar se é realmente necessário — pode gerar explosão de linhas.

Seção 8 — Aplicações Práticas

8.1 — Modelagem Conceitual e Lógica

Informação do Relatório	Ação no Modelo
Tabela com mais joins (Seção 7.1)	Posicione como entidade central / Tabela Fato no diagrama.
Colunas recorrentes em joins (ANO, MES, COD_FORCA)	Crie uma entidade Tempo-Força para simplificar o modelo.
Chaves compostas idênticas em múltiplas tabelas	Identifique entidade implícita que deve ser materializada.
FKs declaradas (Seção 5)	Desenhe relacionamentos obrigatórios (linha sólida).
Pares frequentes sem FK (Seção 7.3)	Adicione relacionamentos implícitos (linha tracejada).

8.2 — Business Intelligence e Data Warehousing

Mapeamento direto do relatório para Star Schema:

Elemento do Star Schema	De onde vem no Relatório
Tabela Fato	Tabela com mais aparições na Seção 7.1
Dimensões principais	Tabelas que formam pares frequentes com a Fato (Seção 7.3)
Granularidade	Colunas da PK da Tabela Fato
Medidas (Métricas)	Colunas NOT NULL, NOT PK, tipo NUMBER na Tabela Fato
Hierarquias	Ordem das colunas nos índices compostos (Seção 3)

Elemento do Star Schema	De onde vem no Relatório
Particionamento sugerido	Colunas com maior frequência na Seção 7.2 (ANO, MES)

8.3 — Machine Learning e KDD

Etapa do KDD/ML	Como o Relatório Ajuda
Seleção de Dados	Identifique Tabela Fato (Seção 7.1) e dimensões relevantes para o problema.
Pré-processamento	Colunas NULL? = YES requerem imputação ou remoção. Liste-as na Seção 2.
Transformação	Colunas CHAR/VARCHAR categóricas são candidatas a one-hot encoding.
Feature Engineering	As colunas mais joinadas (Seção 7.2) são ótimas para features temporais.
Enriquecimento do Dataset	Pares frequentes (Seção 7.3) indicam onde joins são seguros para enriquecer dados.
Performance de Extração	Índices ausentes em Seção 7.2 tornam a extração inviável em grande escala. Corrija antes de treinar.

Seção 9 — Exemplo Prático de Modelagem

Derivando um Mini-Modelo a partir do Relatório

A partir de um relatório típico do BIEG, é possível derivar o seguinte modelo conceitual usando apenas as informações das seções analisadas:

Entidades Derivadas

Fonte no Relatório	Entidade Derivada	Atributos Chave
TB_LANCAMENTOS_FINANCEIROS (447 joins)	LancamentoFinanceiro (Fato)	ID_LANCAMENTO (PK), ANO, MES, COD_FORCA, VALOR, ID_PESSOAL
TB_ATIVOS (116 joins)	MilitarAtivo (Dimensão)	ID_UNICA (PK), ANO, MES, COD_FORCA, ID_PESSOAL
TB_INATIVOS (137 joins)	MilitarInativo (Dimensão)	ID_UNICA (PK), ANO, MES, COD_FORCA, ID_PESSOAL
Seção 7.2 (ANO, MES, COD_FORCA em tudo)	TempoForca (Entidade Implícita)	ANO, MES, COD_FORCA (PK composta)

Recomendações para o Modelo Físico

1. Criar índice ausente: CREATE INDEX idx_lanc_tempo_forca ON TB_LANCAMENTOS_FINANCEIROS (ANO, MES, COD_FORCA);
2. Particionar tabela fato: PARTITION BY RANGE (ANO, MES) para consultas históricas.
3. Adicionar FKs: de LancamentoFinanceiro para as dimensões identificadas.
4. Documentar colunas críticas: priorizar ANO, MES, COD_FORCA, SITUACAO.
5. Criar Surrogate Keys: substituir PKs compostas por IDs numéricos no DW.

Conclusão e Checklist de Ações

O DDL Schema Analyzer DELFOS é uma ferramenta de engenharia reversa de conhecimento. Seu maior valor está em revelar o modelo de dados implícito que não está documentado e em identificar gargalos de performance antes que apareçam em produção.

Checklist de Ações Imediatas

- ☐ Criar índices nas colunas da Seção 7.2 que não possuem ◆ na Seção 2.
- ☐ Definir PKs para as tabelas listadas no Sumário sem chave primária.
- ☐ Documentar colunas de alta frequência nas tabelas mais joinadas (Seção 7.1).
- ☐ Validar relacionamentos implícitos usando os pares da Seção 7.3 para o diagrama ER.
- ☐ Planejar particionamento nas tabelas fato por ANO, MES (colunas de maior frequência).
- ☐ Se usando DELFOS v2: validar que 04_report_real.md e 05_report_original.md são estruturalmente equivalentes.

Alessandro Pessoa da Conceição Barreto
alessandro.pessoa@marinha.mil.br · alessandropessoa@gmail.com