📖 Playbook de Execução Completo: DELFOS (Análise, Anonimização e Validação Científica de DDL)

Objetivo: Guia definitivo para executar a anonimização de esquemas de banco de dados, extrair métricas topológicas, validar a preservação semântica e a eficácia da ofuscação sob múltiplos critérios, garantindo reprodutibilidade (metodologia DSR) e conformidade com a LGPD para uso seguro com Large Language Models (LLMs).

🛠️ Fase 0: Pré-requisitos e Setup do Ambiente

1. Requisitos de Sistema:

- Python 3.12 ou superior.
- Acesso ao repositório local `analisador-delfos` .

2. Instalação de Dependências:

```
cd ~/Documentos/CASNAV/casnav-13/ferramentas-produzidas/analisador-delfos
pip install -r requirements.txt
pip install sqlglot scipy numpy pyyaml
```

3. Preparação do Artefato de Entrada:

- Coloque o arquivo DDL original (ex: `app-adservice.sql`) na raiz do projeto.
- Codificação UTF-8 obrigatória.

🚀 Fase 1: Execução do Pipeline de Anonimização

O pipeline automatizado executa **Mascaramento → Análise do Mock → Desmascaramento do Relatório → Análise do Original**.
No exemplo abaixo rodamos para 3 schemas de bancos diferentes, o primeiro é deum aplicação real em Postgres e os outros dois são sinteticos para experimento
1. Comando Principal:

```
python delfos.py pipeline app-adservice.sql --output-dir ./output-exp-adservice --mo
python delfos.py pipeline schema_oracle.sql --output-dir ./output-exp-oracle --mode
python delfos.py pipeline schema_postgres.sql --output-dir ./output-exp-postgres --m
```

2. Artefatos Gerados (exemplo `./output-exp-oracle/`):

- `01_masked.sql` – DDL anonimizado (seguro para LLMs).
- `02_mapping.json` – **Cofre de reversão** (confidencial).
- `03_structure_masked.json` – Topologia mascarada.
- `05_structure_original.json` – Topologia real (*Ground Truth*).

🧪 Fase 2: Validação Científica Multi-Experimento

O módulo `evaluate.py` agora suporta **múltiplos tipos de experimento**, definidos no arquivo de configuração. Cada experimento valida um aspecto distinto do processo de anonimização.

📂 Estrutura do `evaluate/config.yaml` (Expandida)

```yaml
experiment:
  name: "Validação de Isomorfismo Topológico"
  description: >
    Avalia se a estrutura relacional (SRE) é preservada após o mascaramento.
    Objetivo: Correlação de Pearson > 0,95 com p-valor < 0,05.
  type: "isomorphism"   # Opções: isomorphism, masking_efficacy, cardinality, perfor

sre_weights:            # Pesos para o cálculo do SRE (usado em 'isomorphism')
  pk: 2.0
  fk: 1.5
  idx: 1.0
  joins: 3.0

# Configurações específicas para outros tipos de experimento
masking_efficacy:
  metrics: [substitution_rate, entropy_gain, unique_ratio]
  report_top_occurrences: 10

cardinality:
  compare: [tables, columns, primary_keys, foreign_keys, indexes, views]
  tolerance: 0

performance:
  iterations: 10
  warmup: true
  measure: [parsing_time_ms, memory_usage_mb]

reidentification_risk:
  k_anonymity_threshold: 5
  quasi_identifiers: [table_name_length, column_name_length, prefix_pattern]
  attack_models: [frequency_analysis, pattern_matching]
```

** Cenários de Ajuste:**

- **Bancos Normalizados (OLTP Clássico):** Alta dependência de integridade referencial. Aumente o peso das FKs (`fk: 3.0`).
- **Bancos Analíticos (Data Warehouse/OLAP):** Tabelas fato com particionamentos. Aumente o peso de índices e joins (`idx: 2.5` , `joins: 4.0`).
- **Sistemas Legados ("Tabelas Deusas"):** Poucas FKs explícitas. O balizador principal será a frequência de uso em Views (`joins: 5.0`).

▶ Executando o Avaliador

Comando	Descrição
`python evaluate.py --auto`	Modo legado: busca o primeiro conjunto de artefatos globalmente e executa o tipo definido no `config.yaml` .
`python evaluate.py --dir ./output-exp-oracle`	Executa o experimento **apenas no diretório especificado**.
`python evaluate.py --all`	Varre **todos os diretórios** `output-exp*` e executa o experimento em cada um, gerando um resumo consolidado.
`python evaluate.py --config evaluate/config_risk.yaml --all`	Usa um arquivo de configuração alternativo (ex: para teste de risco de reidentificação).

📊 Tipos de Experimento Disponíveis

Tipo (`type`)	Objetivo	Métricas Geradas
`isomorphism`	Preservação da topologia relacional	Correlação de Pearson, p-valor, tabela SRE por tabela
`masking_efficacy`	Efetividade da ofuscação dos nomes	Taxa de substituição, ganho de entropia, distribuição de hashes
`cardinality`	Integridade da contagem de objetos	Comparação exata de quantidades (tabelas, colunas, FKs, índices, etc.)

Tipo (`type`)	Objetivo	Métricas Geradas
`performance`	Overhead computacional do mascaramento	Tempo médio de parsing, uso de memória
`reidentification_risk`	Risco de reversão do mascaramento	k-anonymity, score de risco, alertas de padrões vazados

Cada execução gera **proveniência** (`provenance_*.json` e `.md`) no diretório do experimento, registrando parâmetros, resultados e metadados do sistema.

📊 Fase 3: Interpretação dos Resultados e Ajuste Metodológico

O *Score de Relevância Estática (SRE)* deve refletir a arquitetura real do banco de dados legado. A equipe de engenharia pode ajustar os pesos metodológicos conforme o paradigma do banco.

🧠 Storytelling Científico (Exemplo para `isomorphism`)

- **Correlação > 0.95 e p-valor < 0.05:** ✅ Isomorfismo validado – a "assinatura geométrica" foi preservada. O DDL mascarado é estatisticamente equivalente ao original.
- **Correlação baixa ou p-valor alto:** ⚠️ A ofuscação alterou a estrutura fundamental. Ajuste os pesos do SRE no `config.yaml` conforme o paradigma do banco:
  - **OLTP Clássico:** Aumente `fk` (ex: 3.0).
  - **Data Warehouse:** Aumente `idx` e `joins` .
  - **Sistemas Legados (poucas FKs):** Aumente drasticamente `joins` .
- **SRE Constante (r=0, p=1):** Schema pequeno ou sem variação suficiente – execute em um DDL mais complexo.

🔍 Interpretação para Outros Tipos de Experimento

Tipo	Interpretação Positiva	Ação Corretiva Sugerida
`masking_efficacy`	Taxa de substituição > 99%, entropia elevada.	Ajustar algoritmo de hash ou comprimento (`--length`).
`cardinality`	Todas as contagens idênticas (tolerância 0).	Revisar parser SQL para dialetos específicos.
`performance`	Tempo < 1s por 10k linhas, uso de memória estável.	Otimizar estruturas de dados ou paralelismo.

Tipo	Interpretação Positiva	Ação Corretiva Sugerida
`reidentification_risk`	k ≥ 5 para todos os quasi-identificadores.	Aumentar aleatoriedade dos hashes ou usar modo `scoped`.

> **Nota Metodológica:** Sempre que alterar pesos ou parâmetros no `config.yaml`, reexecute o avaliador para gerar novos artefatos de proveniência rastreável.

🤖 Fase 4: Integração com LLMs (Engenharia de Prompting)

Com o pipeline validado estatisticamente, o artefato ofuscado pode ser submetido a técnicas de *Few-Shot Prompting* em Large Language Models, ou seja a validação concluída, o DDL mascarado está pronto para ser usado em LLMs.

1. Carregamento de Contexto:
Copie o conteúdo de `01_masked.sql` para o prompt do modelo.

2. Templates de Prompt (Exemplos):

- **Identificação de Core Entities:**
  > *"Atue como um Arquiteto de Dados. Analise o seguinte schema DDL estático. Identifique as 5 tabelas mais críticas (hotspots) do sistema baseando-se exclusivamente na concentração de chaves primárias, dependências de chaves estrangeiras e índices. Explique o porquê da centralidade matemática destas tabelas."*
- **Descoberta de Eixos Temporais:**
  > *"Analise a estrutura de índices e chaves compostas deste DDL. Quais conjuntos de colunas atuam como agrupamentos temporais, versionamentos ou trilhas de auditoria histórica? Descreva a estratégia de particionamento lógico."*
- **Estratégia de Quebra de Monolito (Microserviços):**
  > *"Com base nas constraints deste monolito, proponha a extração de 3 bounded contexts usando os princípios de Clean Architecture. Quais tabelas seriam agrupadas juntas em cada serviço para minimizar o acoplamento?"*

3. Desmascaramento da Resposta do LLM:
Quando o LLM fornecer a análise arquitetural utilizando os nomes falsos (ex: "A tabela `T_8f3a9` e a coluna `C_b4e1` devem formar um microserviço"), traduza os insights de volta para o domínio de negócio real de forma automatizada:

```
# Salve a resposta do LLM em analise_arquitetural.md
python delfos.py unmask ./output-exp-adService/analise_arquitetural.md ./output-exp-

python delfos.py unmask analise_arquitetural.md ./output-exp-postgres/02_mapping.jso
```
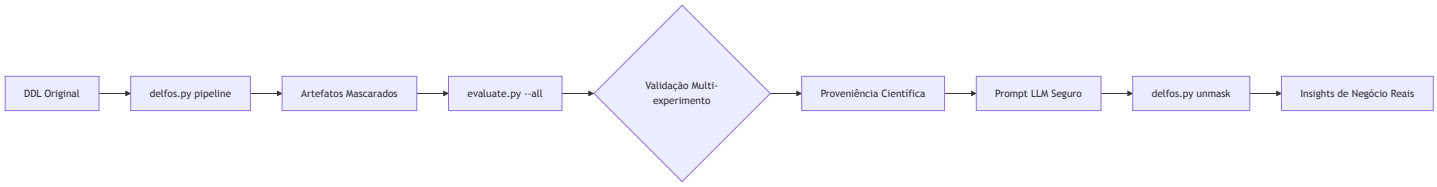
📌 Resumo do Fluxo de Trabalho Atualizado